

Какие специализированные ИИ модели выпускали ИИ ги

Да, это вполне возможно. Но тут важно разделить то, что мы знаем, от того, что предполагаем.

Что известно:

- В большинстве современных архитектур информация о взаимосвязях действительно распределена по многим слоям и головам внимания.
- Ранние слои чаще работают с локальными и синтаксическими зависимостями.
- Поздние слои чаще содержат более абстрактные и семантические связи.
- Веса и активации Transformer содержат много информации о знаниях модели, хотя далеко не всегда в явно декодируемом виде.

Что является гипотезой:

Если модель достаточно хорошо использует причинные, логические и контекстные связи для рассуждений, то некоторые внутренние представления этой модели могут быть переиспользованы для извлечения таких связей и построения графа знаний.

Это звучит логично.

Я бы даже сформулировал архитектурную дилемму.

Вариант А: отдельная модель логики

Prostý text ▾

```
1 Encoder
2 ↓
3 Logic Extractor
```

```
4 ↓
5 Graph
6
```

Плюсы:

- проще обучать;
- проще заменять;
- проще интерпретировать.

Минусы:

- дублирование знаний;
- возможное расхождение между моделью рассуждения и моделью извлечения.

Вариант Б: единая модель

Prostý text ▾

```
1 Encoder
2 ↓
3 Shared Semantic Core
4 | Reasoning
5 | Graph Extraction
6
7
```

Плюсы:

- единое представление мира;
- меньше дублирования.


Минусы:

- сильная связность;
- сложнее развитие системы.

Мне кажется, у вас постепенно возникает третий вариант.

Вариант В: общие представления, разные декодеры

Примерно так:



То есть источником истины становится не диффузная модель и не граф.

Источником становится само латентное пространство.

Если эта гипотеза верна, то очень интересным становится вопрос не "как извлечь связь", а:


На каком слое появляется информация о связи?

Например, связь:



может вообще не существовать ни в одной отдельной голове внимания.

Она может быть распределена по нескольким слоям:



```
4  слой 8
5  распознал контекст
6
7  слой 12
8  сформировал причинную зависимость
9
```

Тогда наблюдение за attention будет недостаточным.

Придётся изучать:

- скрытые состояния (hidden states);
- остаточные потоки (residual stream);
- активации MLP;
- эволюцию представления по слоям.

Честно говоря, из того, что вы описываете, мне сейчас кажется наиболее вероятной не архитектура:

Prostý text ▾

```
1  Диффузия использует граф.
2
```

а скорее:

Prostý text ▾

```
1  Диффузия и граф являются двумя разными проекциями
2  одного и того же латентного представления.
3
```

Тогда во время "сна" можно запускать специальную процедуру:

Prostý text ▾

```
1  Чанк текста
2  ↓
3  Encoder
4  ↓
5  Latent Representation
6  ↓
7  Graph Extraction Head
```

```
8 ↓
9 Новые связи
10
```

а во время инференса:

```
1 Запрос
2 ↓
3 Encoder
4 ↓
5 Latent Representation
6 ↓
7 Graph Retrieval
8 ↓
9 Diffusion Reasoning
10 ``
11
```

Prostý text ▾

И самое интересное здесь то, что граф фактически становится не источником знаний, а материализованной интерпретацией того, что уже закодировано в латентном пространстве. Если такой подход сработает, то проблема "постоянного дообучения логического эксперта" практически исчезает. Нужно будет обновлять граф и, возможно, периодически дообучать общий энкодер, но не поддерживать гигантский набор отдельных причинных экспертов.